Классификация зашифрованного сетевого трафика: анализ качества и устойчивости моделей по метаданным

Дмитрий Панюгин
СУНЦ МГУ

Ключевые слова

машинное обучение, классификация трафика, устойчивость моделей, fragility analysis, разреживание признаков, PCA

Содержание

1 Аннотация **4**

2 Abstract **4**

3 Введение **5**

4 Данные и признаковое пространство **5**

4.1 Данные 5

4.2 Признаковое пространство 5

5 Методология **6**

5.1 Архитектуры моделей 6

5.2 Предобработка данных 6

5.3 Профили предобработки 7

5.4 Снижение размерности (PCA) 8

5.5 Метрика качества 8

6 Цели проекта **8**

7 Протокол эксперимента **9**

8 Результаты **9**

8.1 Анализ качества моделей в пространстве Precision–Recall 9

8.2 Сравнение архитектур моделей 10

8.3 Влияние снижения размерности (PCA) 11

8.4 Анализ разреживания признаков (Sparsification) 12

8.5 Анализ устойчивости моделей 14

8.6 Сравнение моделей по метрике Fragility 15

9 Обсуждение **16**

10 Ограничения **17**

11 Выводы и дальнейшая работа **17**

12 Заключение **19**

1 Аннотация

В данной работе проводится анализ качества и устойчивости моделей классификации VPN-трафика на основе метаданных. Исследуется влияние архитектуры модели и профиля предобработки данных на итоговое качество классификации. Показано, что выбор архитектуры оказывает доминирующее влияние на метрики качества по сравнению с настройками препроцессинга. Отдельно исследуется влияние метода главных компонент (PCA) на качество и стабильность моделей. Для оценки устойчивости моделей к искажениям входных данных применяется анализ хрупкости (fragility analysis), который демонстрирует, что модели с сопоставимым качеством могут существенно различаться по стабильности при воздействии аномалий.

2 Abstract

This paper presents an analysis of the quality and robustness of VPN traffic classification models based on metadata. The influence of the model architecture and data preprocessing profile on the final classification quality is investigated. It is shown that the choice of architecture has a dominant impact on quality metrics compared to preprocessing settings. The effect of Principal Component Analysis (PCA) on model quality and stability is studied separately. To assess the robustness of models to input data distortions, fragility analysis is applied, demonstrating that models with comparable quality can differ significantly in stability under anomaly exposure.

3 Введение

Классификация зашифрованного трафика методами глубокой инспекции пакетов (DPI) затруднена из-за использования туннелирования и обфускации. Альтернативой выступает машинное обучение на основе статистических метаданных потоков данных.

Для обучения моделей используется датасет VPN and Non-VPN Application Traffic (CIC-VPN2016).

4 Данные и признаковое пространство

4.1 Данные

Используется датасет сетевого трафика, содержащий бинарную разметку на два класса (зашифрованный / обычный трафик). Выборка включает ∼60 000 сетевых потоков. Отношение размера обучающей выборки к тестовой train/test = 70/30

4.2 Признаковое пространство

Модели используют агрегированные на уровне сетевого потока метаданные (flow-based metadata). Ниже приведён перевод описания основных признаков:

- `duration` — общая длительность потока в микросекундах;
- `total_fiat` — суммарное время между последовательными пакетами в прямом направлении (Forward Inter-Arrival Time);
- `total_biat` — суммарное время между последовательными пакетами в обратном направлении (Backward Inter-Arrival Time);
- `min_fiat` / `min_biat` — минимальный интервал между пакетами в прямом/обратном направлении;
- `max_fiat` / `max_biat` — максимальный интервал между пакетами в прямом/обратном направлении;

- `mean_fiat` / `mean_biat` — средний интервал между пакетами в прямом/обратном направлении;
- `flowPktsPerSecond` — количество пакетов в потоке за секунду;
- `flowBytesPerSecond` — количество байт в потоке за секунду.

Типы признаков:

- **Временные** — длительность потока, интервалы между пакетами (IAT);
- **Статистические** — среднее, стандартное отклонение, минимум, максимум длин пакетов;
- **Направленные (directional)** — статистики, разделённые по направлениям forward/backward.

5 Методология

5.1 Архитектуры моделей

Рассматриваются следующие архитектуры:

- **Градиентный бустинг (Gradient Boosting)** — ансамблевый метод над табличными данными;
- **XGBoost** — оптимизированная реализация градиентного бустинга;
- **Деревья и бэггинг (Bagging/RF)** — методы на основе независимых решающих деревьев;
- **Стекинг (Stacking)** — мета-алгоритм, объединяющий предсказания базовых моделей.

5.2 Предобработка данных

Независимо от выбранного профиля, предобработка данных выполняется по единой схеме. Профили различаются только составом операций внутри отдельных этапов. Общий порядок обработки:

1. **Фильтрация признаков** — удаление части исходных признаков в соответствии с выбранным профилем (например, исключение шумных или нерелевантных характеристик);

2. **Преобразование признаков** — при необходимости выполняется генерация новых признаков или модификация существующих (например, агрегации или взаимодействия);

3. **Обработка выбросов** — в отдельных профилях применяется ограничение экстремальных значений признаков;

4. **Масштабирование** — приведение признаков к единому масштабу с использованием стандартной нормализации;

5. **Снижение размерности (опционально)** — при включении PCA данные проецируются в пространство меньшей размерности;

6. **Передача в модель** — подготовленные признаки используются для обучения и предсказания.

Таким образом, каждый профиль задаёт конкретную реализацию отдельных шагов, но не изменяет общую структуру пайплайна.

5.3 Профили предобработки

В исследовании используются несколько профилей предобработки, каждый из которых задаёт стратегию работы с признаковым пространством:

- `default` — минимальная обработка: используется исходный набор признаков;

- `drop_active_idle` — упрощение признакового пространства за счёт удаления малоинформативных групп признаков, связанных с активностью и простоями потока;

- `clean_max_biat` — агрессивная очистка признаков: исключаются экстремальные и нестабильные характеристики (все максимумы), чтобы снизить влияние выбросов;

- `feature_engineering` — расширение признакового пространства за счёт генерации дополнительных признаков и взаимодействий между ними;
- `quantile_profile` — подавление выбросов путём ограничения значений признаков на основе квантилей (clipping), что делает распределения более устойчивыми.

Таким образом, профили охватывают три основных подхода: упрощение признаков, их расширение и стабилизацию распределений.

5.4 Снижение размерности (PCA)

Метод главных компонент (PCA) выделяется в отдельный этап пайплайна, применяемый после препроцессора и масштабирования (StandardScaler). Порог объяснённой дисперсии установлен на уровне 95%. PCA проецирует данные в ортогональное пространство меньшей размерности, помогая отбросить ненужные признаки.

5.5 Метрика качества

В качестве основной метрики для оценки качества классификации используется F1-мера:

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}, \tag{1}$$

где точность (Precision) и полнота (Recall) определяются следующим образом:

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}, \tag{2}$$

где TP — истинно-положительные, FP — ложно-положительные, FN — ложно-отрицательные классификации.

6 Цели проекта

- Создание модели классификации VPN-трафика, устойчивой к выбросам и аномалиям.
- Оценка влияния архитектуры и профиля препроцессинга на качество.

- Исследование влияния снижения размерности (PCA) на качество и стабильность моделей.
- Количественная оценка устойчивости моделей к контролируемым искажениям.

7 Протокол эксперимента

Для каждой модели применяется единый pipeline обработки данных. Один эксперимент представляет собой комбинацию «архитектура модели + профиль предобработки + флаг PCA». Оценка качества проводилась на отложенной тестовой выборке.

8 Результаты

8.1 Анализ качества моделей в пространстве Precision–Recall

На рисунке 8.1.1 представлено распределение моделей в пространстве Precision–Recall с изолиниями F1-метрики. Большинство моделей сосредоточено в диапазоне $F1 \in [0.90, 0.95]$. Профили предобработки и смена архитектуры незначительно влияют на результат. При этом их близость к идеальной зоне подтверждает хорошую разделимость классов.

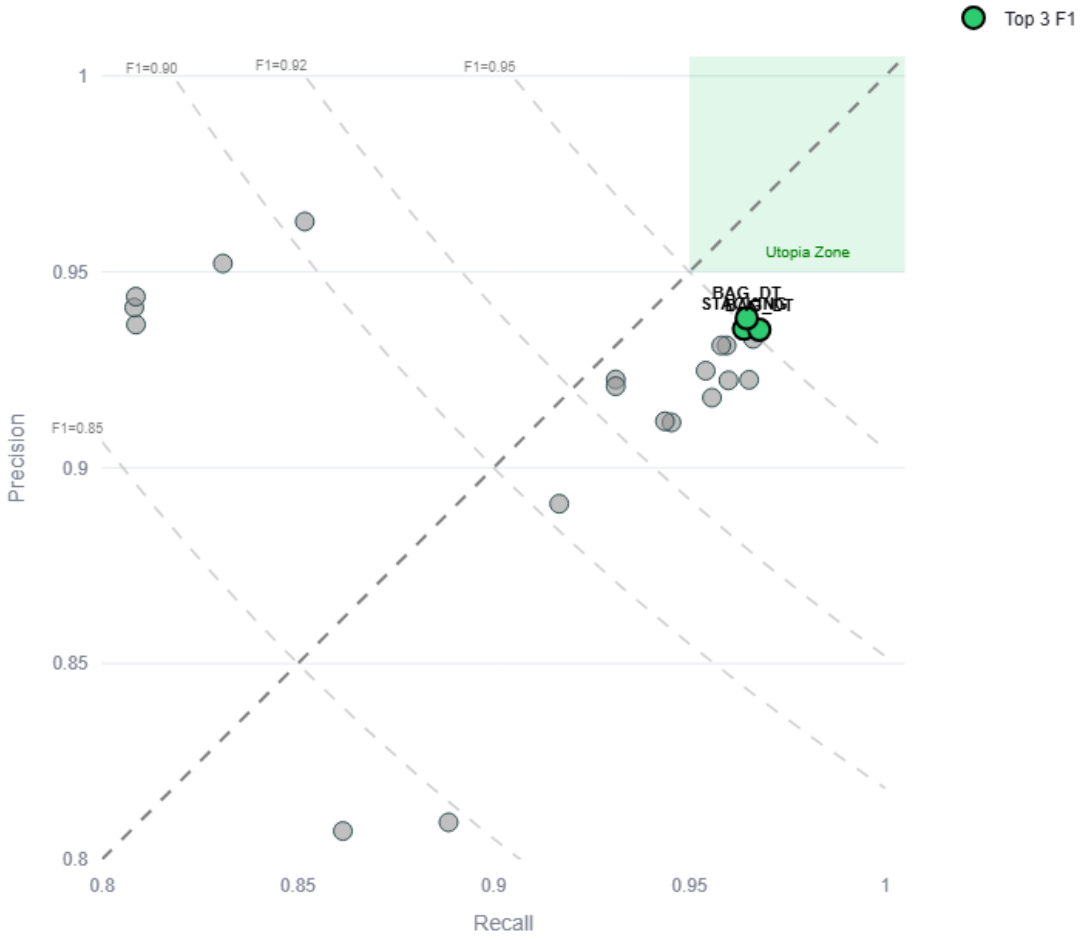

Рис. 8.1.1: Распределение моделей в пространстве Precision–Recall с изолиниями F1.

8.2 Сравнение архитектур моделей

Разброс значений F1 между различными архитектурами моделей визуально превышает разброс, обусловленный изменением профилей предобработки.

Модели на основе градиентного бустинга (XGBoost) и стекинговые модели на основе него же формируют верхнюю границу качества, в то время как одиночные деревья и бэггинг демонстрируют больший разброс и более низкие медианные значения.

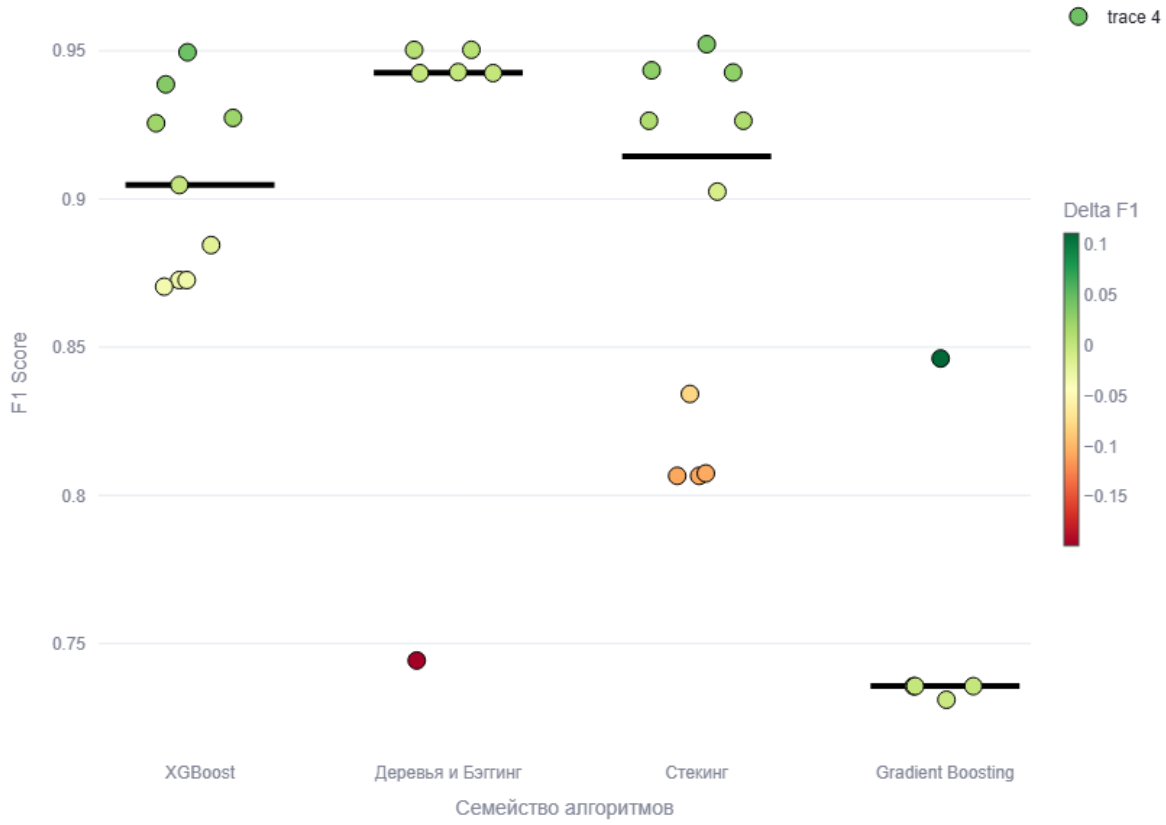

Рис. 8.2.1: Сравнение моделей по качеству (F1) для различных архитектур.

8.3 Влияние снижения размерности (PCA)

Поскольку изначальное признаковое пространство небольшое (< 15 признаков), влияние PCA будет изучено на профиле препроцессинга feature_engineering, который создаёт > 500 признаков взаимодействия исходных признаков. На рисунке 8.3.1 показано изменение F1-меры при включении этапа PCA по сравнению с моделью той же архитектуры и препроцессинга без PCA ($\Delta F1 = F1_{PCA} - F1_{no_PCA}$).

Применение PCA систематически снижает качество классификации: $\Delta F1 \approx -0.01 \ldots - 0.03$ для большинства архитектур. Это ухудшение ожидаемо и обусловлено механикой построения решающих правил. Tree-based модели используют пороговые разбиения по одному признаку в каждом узле (axis-aligned splits). PCA формирует компоненты как линейные комбинации всех исходных признаков, разрушая осевую структуру данных и затрудняя выде-

ление дискриминирующих паттернов. Линейные модели (Logistic Regression) менее чувствительны к данному преобразованию, поскольку разделяющая гиперплоскость инвариантна к полному линейному преобразованию пространства признаков. Кроме того, PCA максимизирует дисперсию, а не межклассовую разделимость, поэтому отбрасываемые компоненты могут содержать критически важную для классификации информацию.

Таким образом, применение PCA в задаче классификации табличных данных с последующим использованием tree-based моделей приводит к ухудшению качества из-за потери интерпретируемой осевой структуры признаков, несмотря на сокращение размерности.

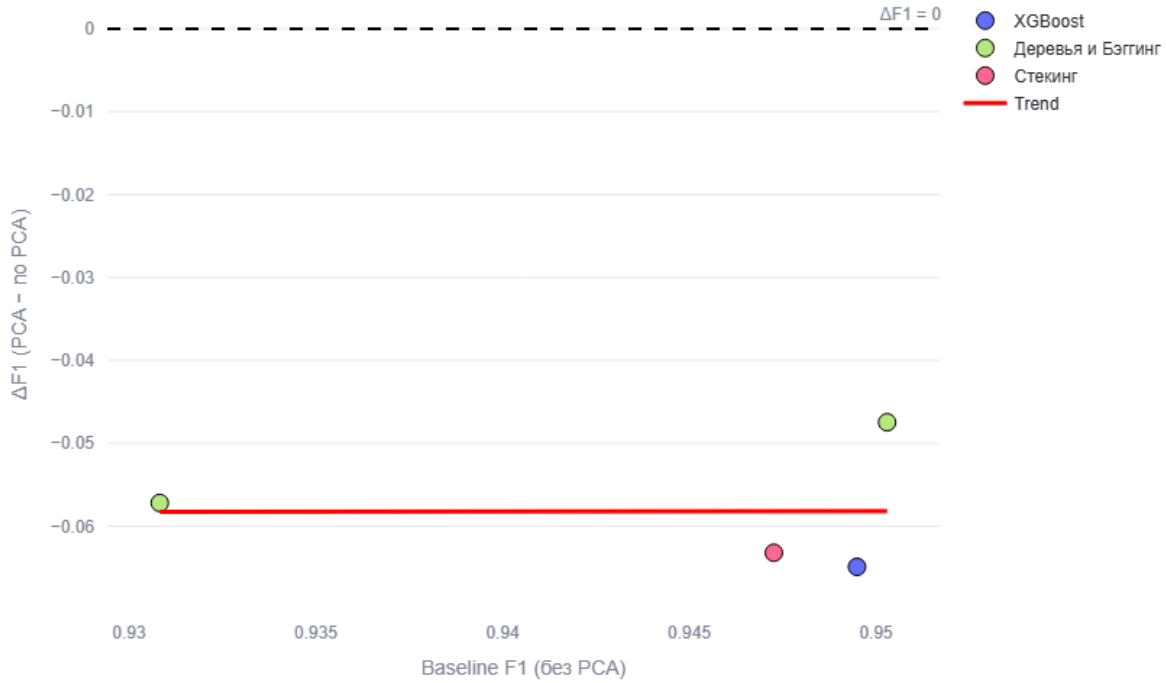

Рис. 8.3.1: Изменение F1-меры при применении PCA ($\Delta F1 = F1_{PCA} - F1_{no_PCA}$) для различных архитектур. Отрицательные значения соответствуют ухудшению качества.

8.4 Анализ разреживания признаков (Sparsification)

Анализ зависимости качества от числа важных признаков проведён с разделением моделей на стабильные (дисперсия F1 ниже медианы) и нестабильные (дисперсия F1 выше медианы).

- Для стабильных моделей наблюдается монотонная зависимость качества от числа используемых признаков, близкая к линейной, что указывает на устойчивое использование информации без переобучения;

- На графике для нестабильных моделей дополнительно отображаются «усы» (error bars), характеризующие вариативность качества модели. Усы соответствуют диапазону изменения F1-метрики при различных конфигурациях (архитектура, профиль предобработки, использование PCA) и отражают разброс значений относительно среднего. Чем больше маркер и длиннее усы, тем выше чувствительность модели к изменениям признакового пространства и параметров пайплайна.

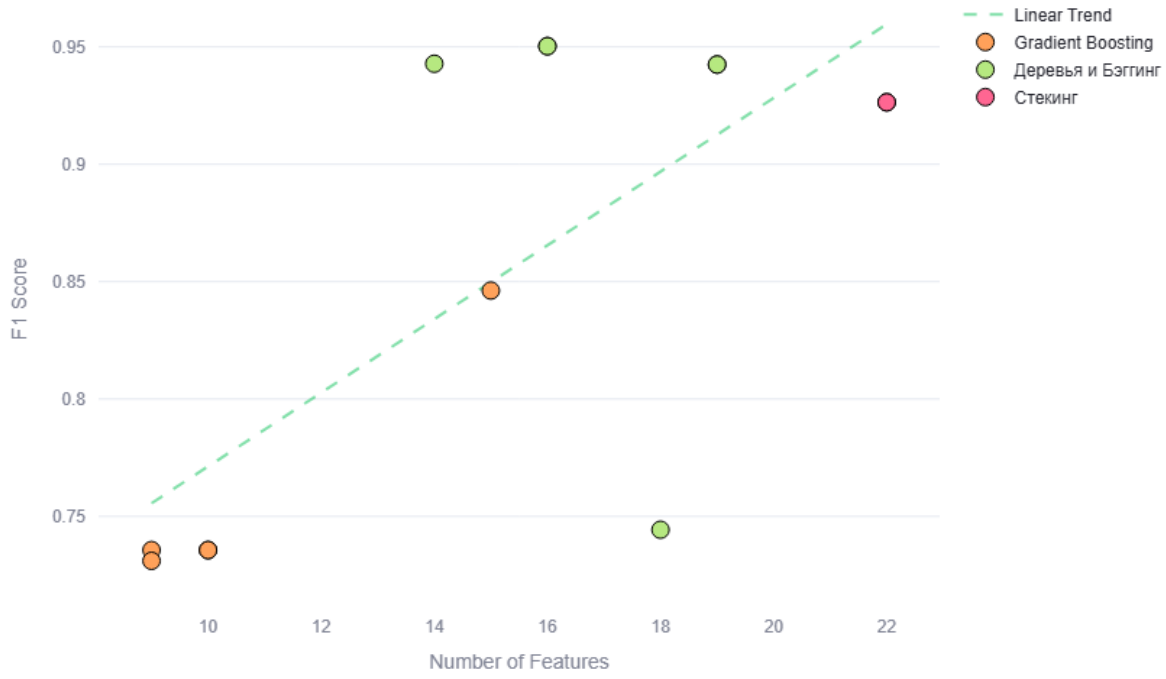

Рис. 8.4.1: Зависимость качества от числа признаков для стабильных моделей.

Рис. 8.4.2: Зависимость качества от числа признаков для нестабильных моделей.

8.5 Анализ устойчивости моделей

К контролируемым искажениям входных данных (дефляция min значений с множителями x2, x5, x10) модели демонстрируют различную чувствительность. На рисунке 8.5.1 показано, что при искажении x10 падение F1 достигает 40% для наименее устойчивых архитектур, в то время как устойчивые модели теряют не более 29%. Отдельно выделяется decision tree, который демонстрирует наибольшую деградацию качества и устойчивости среди рассмотренных моделей.

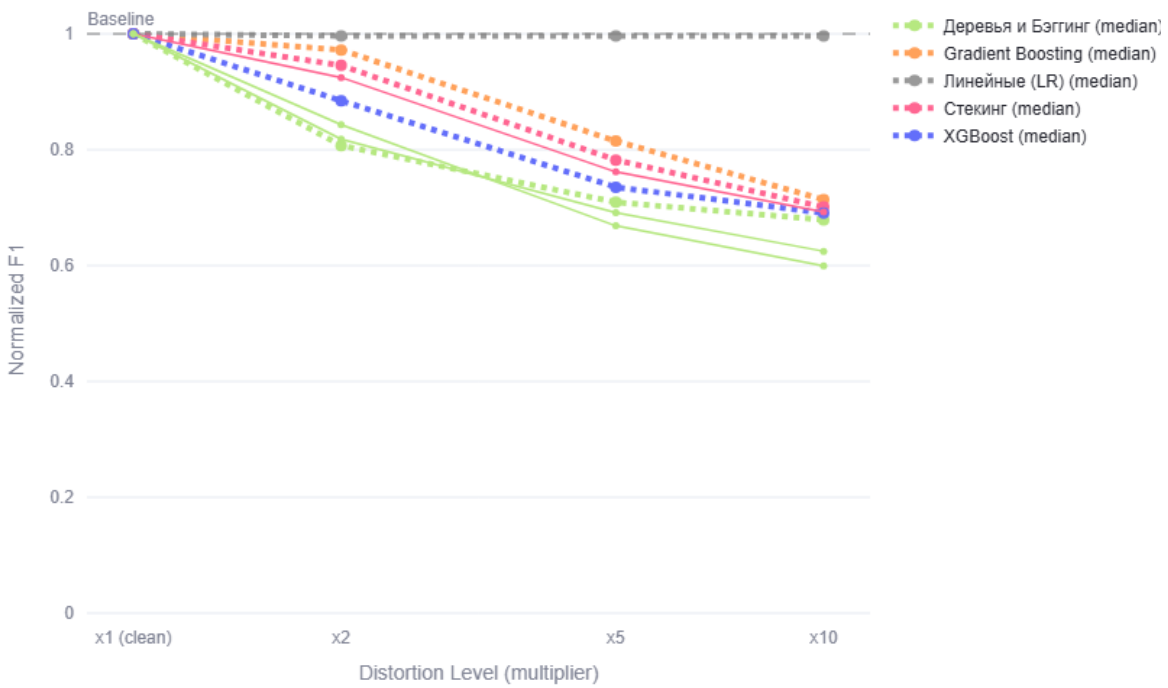

Рис. 8.5.1: Зависимость нормализованной F1-метрики от уровня искажения данных.

8.6 Сравнение моделей по метрике Fragility

Интегральная метрика Fragility определяется как сумма падений F1 относительно базового уровня на всех уровнях искажения:

$$Fragility = \sum_k \left(F1_{baseline} - F1_{distortion_k}\right)$$

. На рисунке 8.6.1 Pareto-оптимальные модели (преимущественно XGBoost и стекинг по xgb) обладают высоким качеством ($F1 > 0.93$) при средней хрупкости ($fragility > 0.4$), в то время, как gb показывает среднее значение метрики F1 (=0.7) при низкой хрупкости около 0.2. Вывод: использование только F1-метрики недостаточно для выбора лучшей модели.

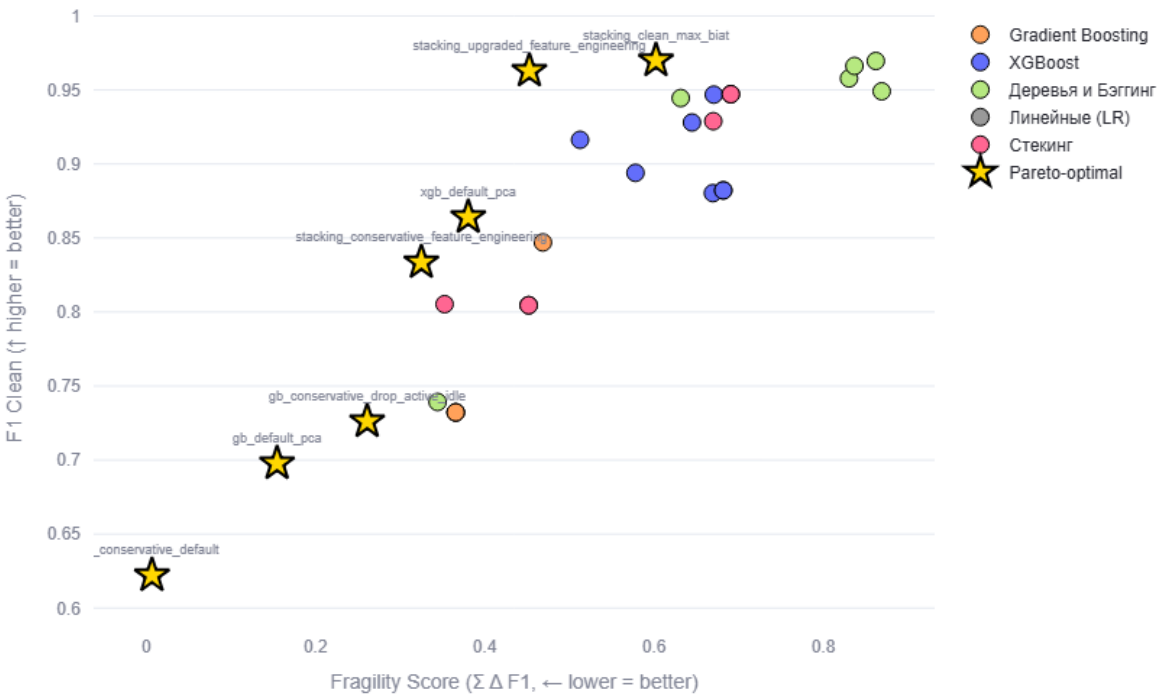

Рис. 8.6.1: Сравнение моделей по качеству и устойчивости (F1 vs Fragility).

9 Обсуждение

Полученные результаты объясняются свойствами моделей. Tree-based алгоритмы устойчивы к искажениям, так как используют пороговые разбиения (piecewise-constant функции), нечувствительные к монотонным преобразованиям и выбросам масштаба. Этим же объясняется незначительное влияние профилей предобработки: деревья решений нативно обрабатывают ненормализованные данные с экстремальными значениями.

В рамках проведённого эксперимента архитектура модели оказывает более заметное влияние на качество, чем профиль предобработки, но при этом использование профиля предобработки, отличного от базового, улучшает качество модели любой архитектуры. Как показано в разделе 8.3, применение PCA систематически ухудшает качество tree-based моделей из-за разрушения осевой структуры признаков.

Выбор модели должен опираться на баланс F1 и fragility score. Модель с высоким F1, но большой хрупкостью деградирует при естественном дрифте

распределений сетевого трафика.

10 Ограничения

Исследование имеет следующие ограничения:

- Результаты зависят от специфики использованного датасета и могут не обобщаться на принципиально иные топологии сетей.
- Рассмотрены только механические искажения признаков (дефляция); целенаправленные adversarial атаки на уровне потоков не проводились.
- Порог PCA зафиксирован на уровне 95% объяснённой дисперсии; влияние других порогов не исследовано.
- Набор профилей предобработки не включает нелинейные методы снижения размерности (UMAP, t-SNE), неприменимые к обучению с учителем в рамках данного pipeline.

11 Выводы и дальнейшая работа

В работе проведён комплексный анализ моделей классификации VPN-трафика на основе метаданных потоков. Показано, что архитектура модели оказывает существенно большее влияние на качество классификации, чем используемый профиль предобработки данных. Наилучшие результаты по F1-метрике демонстрируют ансамблевые методы на основе градиентного бустинга, в частности XGBoost и стекинговые подходы.

Установлено, что применение метода главных компонент (PCA) в рассматриваемой задаче приводит к систематическому снижению качества классификации, особенно для моделей, основанных на деревьях решений. Это связано с потерей осевой структуры признакового пространства, критически важной для работы таких алгоритмов.

Введённый анализ хрупкости (fragility analysis) позволил количественно оценить устойчивость моделей к искажениям входных данных. Показано, что модели с близкими значениями F1 могут существенно различаться по степени

устойчивости, что указывает на необходимость многокритериального подхода при выборе модели.

Таким образом, выбор оптимальной модели должен учитывать не только качество классификации, но и её устойчивость к изменениям распределения данных.

В качестве направлений дальнейших исследований рассматриваются:

- анализ устойчивости моделей к целенаправленным adversarial-атакам на уровне сетевых потоков;
- исследование влияния различных порогов объяснённой дисперсии в PCA;
- применение альтернативных методов снижения размерности и отбора признаков;
- разработка методов автоматического поиска моделей, оптимальных по критериям качества и устойчивости.

12 Заключение

Предложен визуальный и количественный аппарат для оценки качества и устойчивости, включающий изолинии F1, разделение моделей по стабильности, анализ влияния PCA и метрику хрупкости. Применение данного подхода позволяет обоснованно выбирать модели, сохраняющие работоспособность при деградации и зашумлении входных данных.